

Na regressão logística, para cada ponto nos dados temos o vetor x_i e uma classe observada y_i . A probabilidade pode ser P , se $y_i = 1$ ou $1 - P$ se $y_i = 0$. A verossimilhança é dada então, por:

$$L = \prod_{i=1}^n P(x_i)^{y_i} (1 - P(x_i))^{1-y_i}$$

Como $P(C=1|x) = \sigma(w^T x + b)$, sendo $D = \{(x^n, c^n), n=1, \dots, N\}$

$$L = \prod_{i=1}^n \sigma(w^T x^i + b)^{c^i} (1 - \sigma(w^T x^i + b))^{1-c^i} \quad c^n \in \{0, 1\}, \text{ temos:}$$

$$\log L = \sum_i c^i \log \sigma(w^T x^i + b) + (1 - c^i) \log (1 - \sigma(w^T x^i + b))$$

Como a derivada de $\log_e \sigma(w^T x^n + b) = \frac{\sigma'}{\sigma(w^T x^n + b)}$ (com relação a w),

e observando que:

$$\sigma(x) = \frac{1}{1 + e^{-\lambda x}}, \quad \sigma'(x) = \frac{-\lambda e^{-\lambda x}}{(1 + e^{-\lambda x})^2} = \sigma(x)^2 (-\lambda e^{-\lambda x}),$$

$$\lambda e^{-\lambda x} = \frac{\lambda(1 - \sigma)}{\sigma} \Rightarrow \sigma' = \sigma(1 - \sigma), \text{ temos}$$

$$\nabla_w L = \sum_i c^i (1 - \sigma(w^T x^i + b)) x^i - (1 - c^i) \sigma(w^T x^i + b) x^i$$

Com $i = n$ e simplificando a expressão acima:

$$\nabla_w L = \sum_{n=1}^N (c^n - \sigma(w^T x^n + b)) x^n \quad \blacksquare$$